MAS: Betriebssysteme

Koordination und Synchronisation:
Monitore, Java-Synchronisation und Verklemmungen

T. Pospíšek

Gesamtüberblick

1. Einführung in Computersysteme
2. Entwicklung von Betriebssystemen
3. Architekturansätze
4. Interruptverarbeitung in Betriebssystemen
5. Prozesse und Threads
6. CPU-Scheduling
7. **Synchronisation und Kommunikation**
8. Speicherverwaltung
9. Geräte- und Dateiverwaltung
10. Betriebssystemvirtualisierung

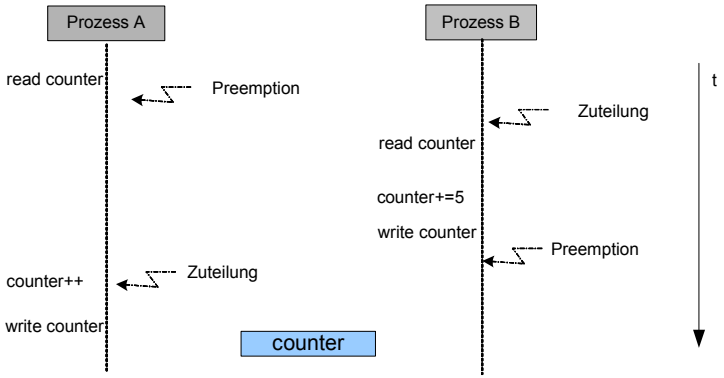

Zielsetzung

- Der Studierende soll verstehen, wie Monitore funktionieren und welche Vorteile sie gegenüber Semaphoren haben
- Der Studierende soll Java-Monitore und deren Anwendung verstehen
- Der Studierende soll wissen, was Deadlocks sind und wie man sie vermeiden bzw. erkennen und beheben kann

Überblick

1. **Monitore**
2. Java-Synchronisation
3. Deadlocks

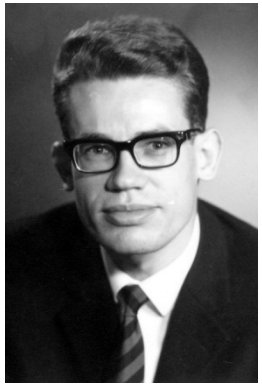

1959

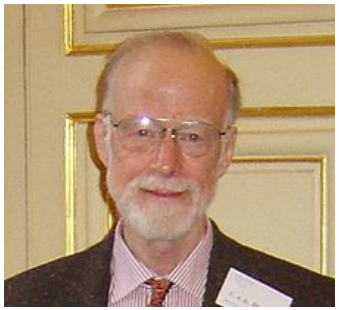

Sir Charles Antony Richard Hoare (11.01.1934)
Britischer Computerwissenschaftler

Per Brinch Hansen (13.11.1938 – 31.07.2007),
Dänisch-Amerikanischer Computer-Wissenschaftler

Monitore

- Die Nutzung von Semaphoren ist zwar eine Erleichterung, aber nicht unproblematisch
  - Man kann als Programmierer eine Operation vergessen
  - Man kann sie versehentlich verwechseln
  - **V**(); ... Kritischer Abschnitt ...; **P**();
    - führt z.B. dazu, dass alle Prozesse im kritischen Abschnitt zugelassen sind
- **Hoare** und **Brinch Hansen** schlugen daher vor, die Erzeugung und Anordnung der Semaphoroperationen dem Compiler zu überlassen
  - Sie entwickelten einen Abstrakten Datentypen für diese Zwecke (1973/1974), den sie mit **Monitor** bezeichneten
- In einem Monitor werden gemeinsam benutzte Daten durch eine Sperre und durch Synchronisationsvariablen (Conditions) geschützt

Monitore

- Nach Richter versteht man unter einem Monitor
  - eine Menge von Prozeduren und Datenstrukturen, die als Betriebsmittel betrachtet werden
  - und mehreren Prozessen zugänglich sind,
  - aber nur von einem Prozess/Thread zu einer Zeit benutzt werden können

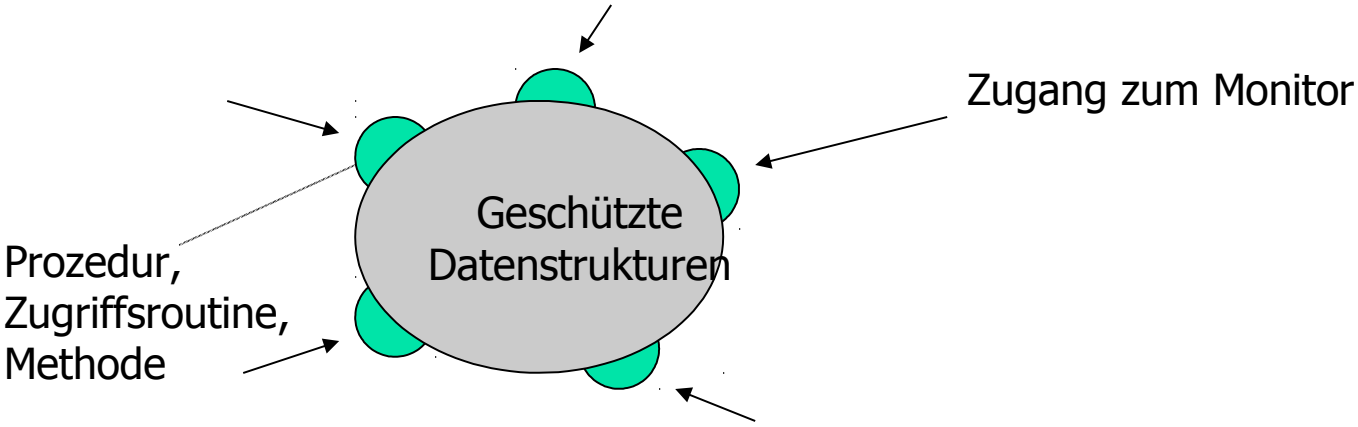

Monitore: Grundstruktur

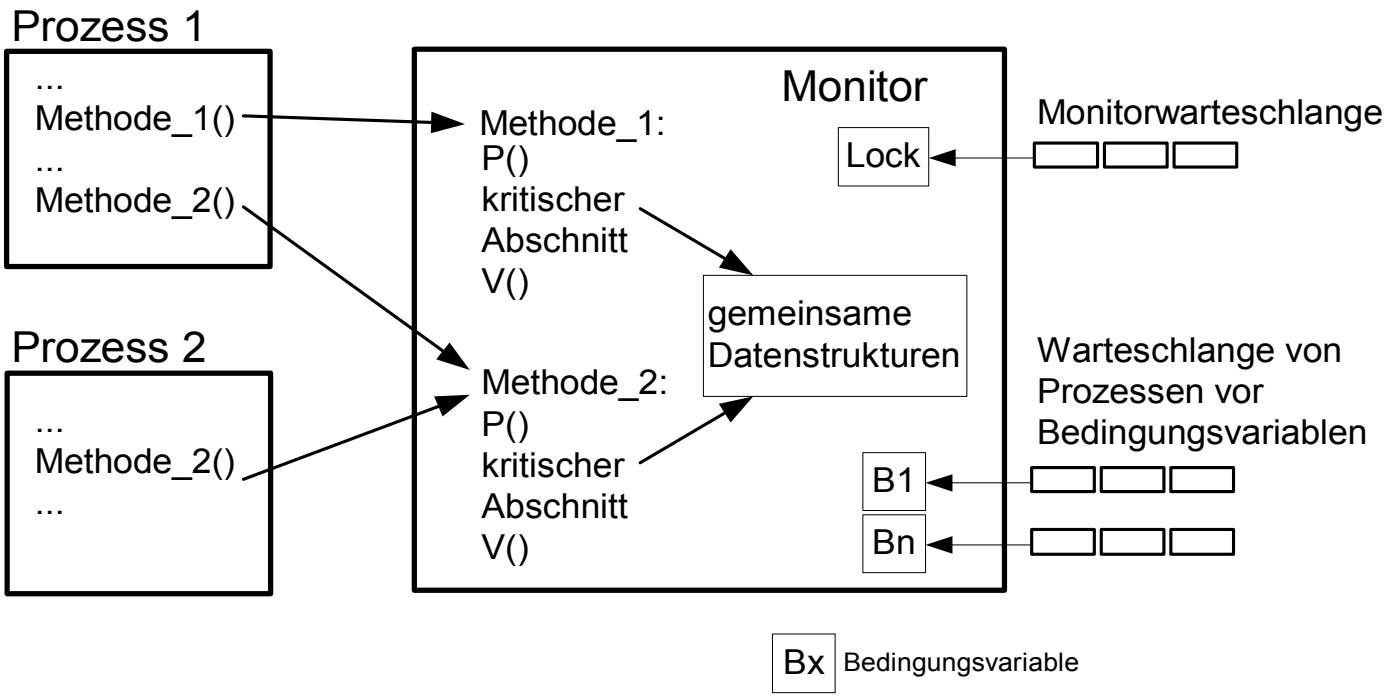

Monitore, Beispielnutzung Producer-Consumer (1)


```
Monitor ProducerConsumer
{
    final static int N = 5;                 // Maximale Puffergröße
    static int count = 0;                   // Anzahl gefüllte Pufferbereiche
    condition not_full;                     // Signal -> Puffer nicht voll
    condition not_empty;                    // Signal -> Puffer nicht leer
    …


    void insert(item: integer) {
        if (count == N) wait(not_full); // Warten bis Puffer
                                        // nicht mehr voll ist
        // Insert item
        count+=1;
        if (count == 1) signal(not_empty);
    }

    item remove() {
        if (count == 0) wait(not_empty); // Warten bis Puffer
                                         // nicht mehr leer ist
        // Remove item
        count--;
        if (count == (N-1)) signal(not_full);
        return (item);
    }
}
```

Die condition-Variablen werden in zwei Operationen genutzt:

- signal
- wait

Bei Aufruf von wait wird der Monitor verlassen. Zwei Ansätze:

- signal-and-continue
- signal-and-wait

Ein anderer Prozess kann ihn betreten → wichtig!

Quelle: *Tanenbaum, A. S.*: Moderne Betriebssysteme, 3. aktualisierte Auflage, Pearson Studium, 2009

Monitore, Beispielnutzung
Producer-Consumer (2)

Zürcher Hochschule für Angewandte Wissenschaften
School of Engineering

```
class UseMonitor
{
    ProducerConsumer mon = new ProducerConsumer();
    ...
    void producer() {
        while (true) {
            // produce item
            mon.insert(item);
        }
    }

    void consumer() {
        while (true) {
            item = mon.remove();
            // consume item
        }
    }
}
```

Quelle: *Tanenbaum, A. S.*: Moderne Betriebssysteme, 3. aktualisierte Auflage, Pearson Studium, 2009

Monitore, Producer-Consumer, Szenario 1 (1)

- Initialzustand: Nichts produziert, nichts konsumiert

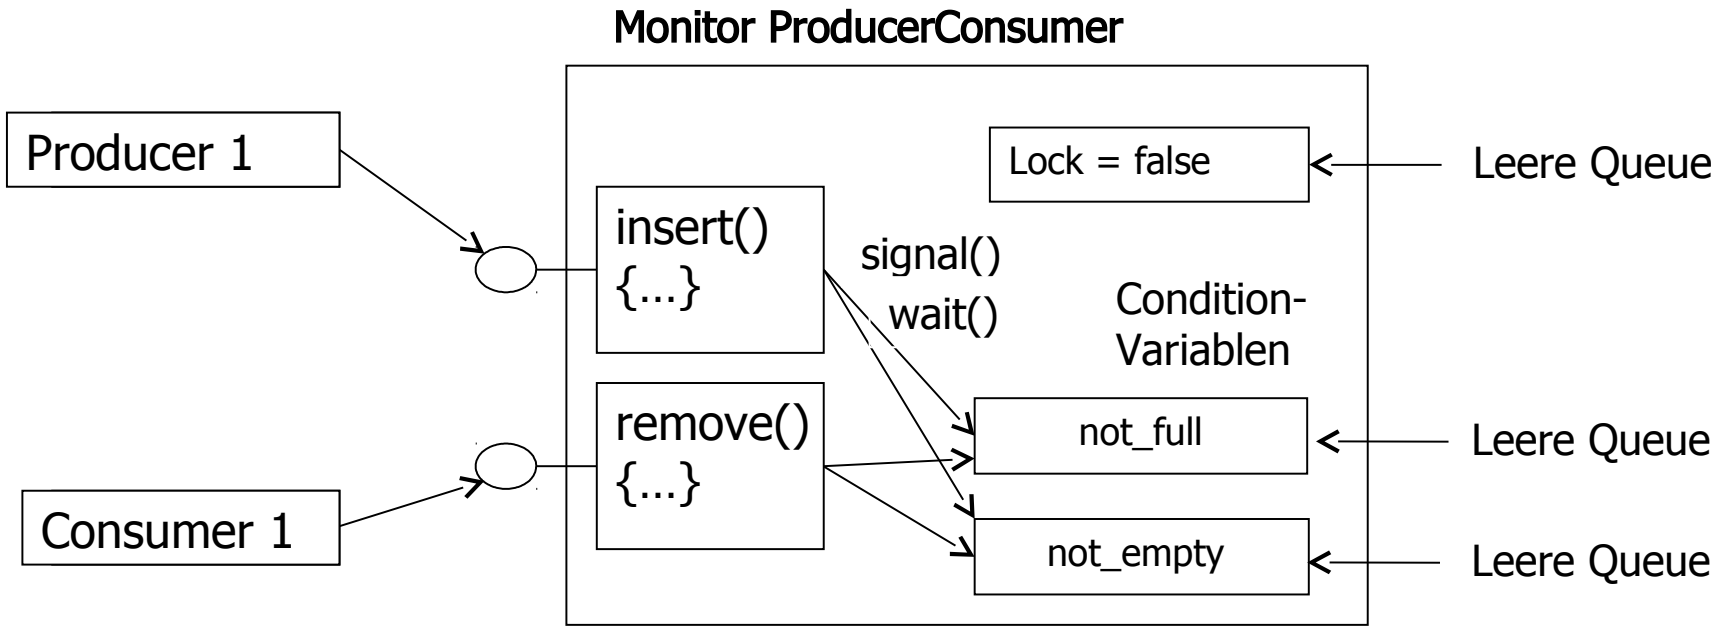

Monitore, Producer-Consumer, Szenario 1 (2)

- Consumer 1 möchte als erster konsumieren

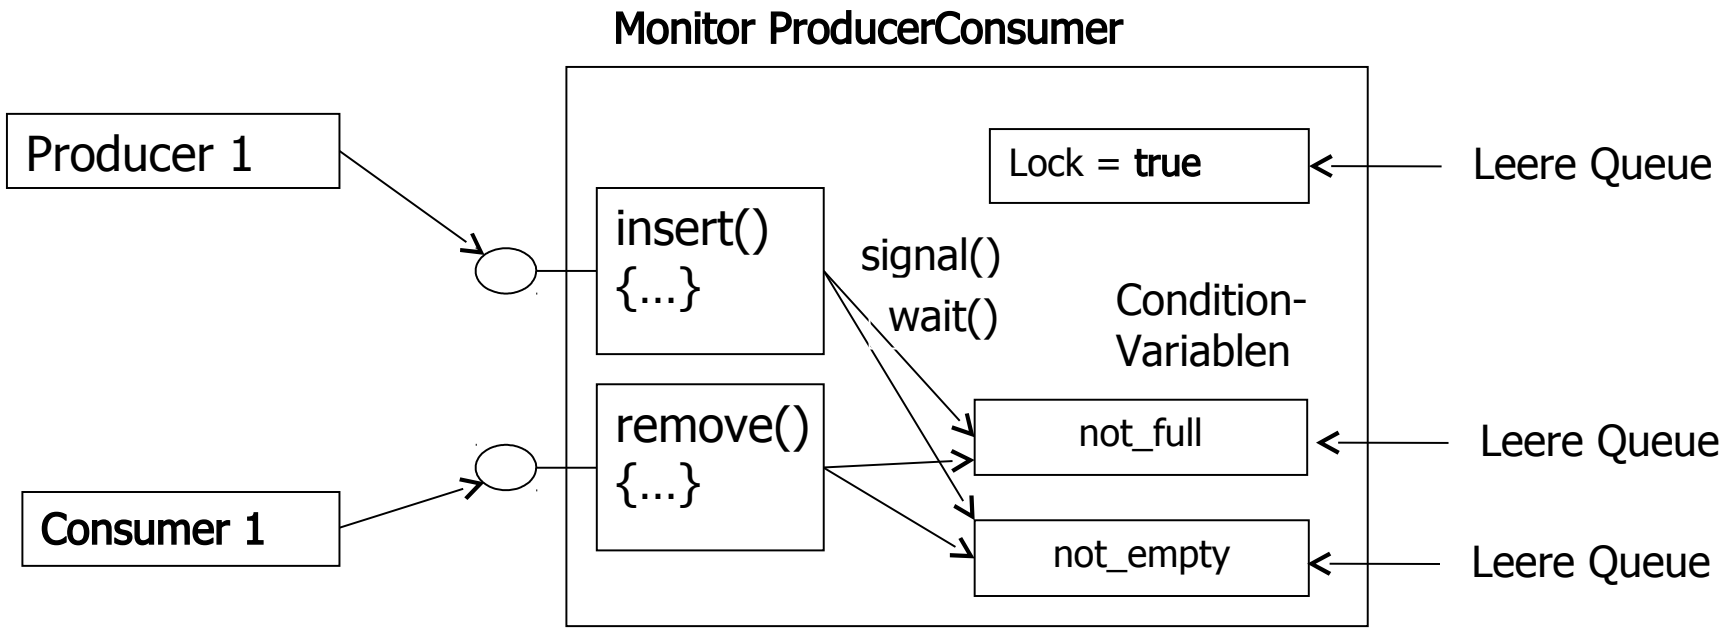

Monitore, Producer-Consumer, Szenario 1 (3)

- Consumer 1 möchte als erster konsumieren, Producer 1 kommt später und muss warten

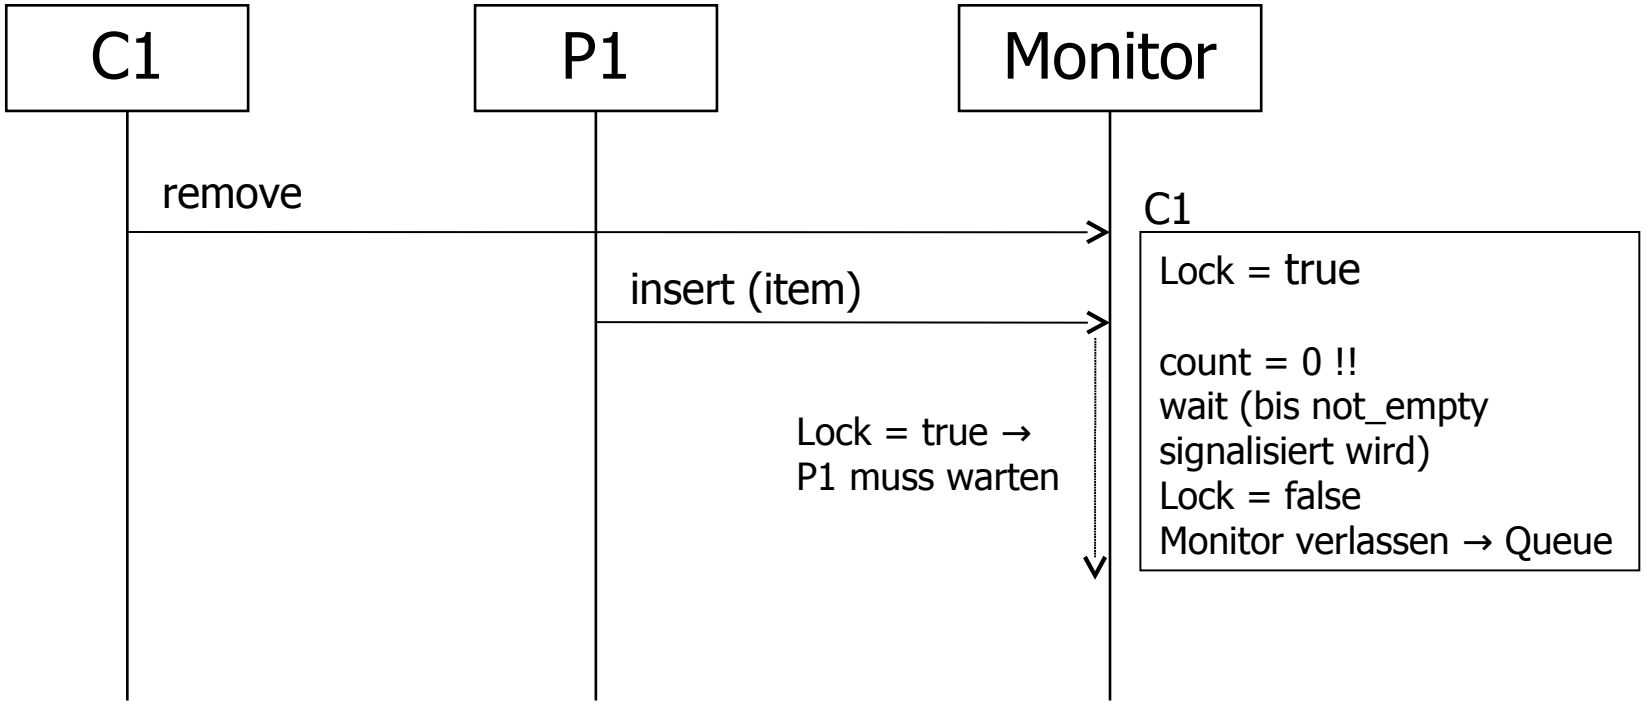

Monitore, Producer-Consumer, Szenario 1 (4)

- Consumer 1 kann nichts vorfinden (kein Item)
- Producer 1 wartet bis Consumer 1 den Monitor verlassen hat und betritt ihn dann

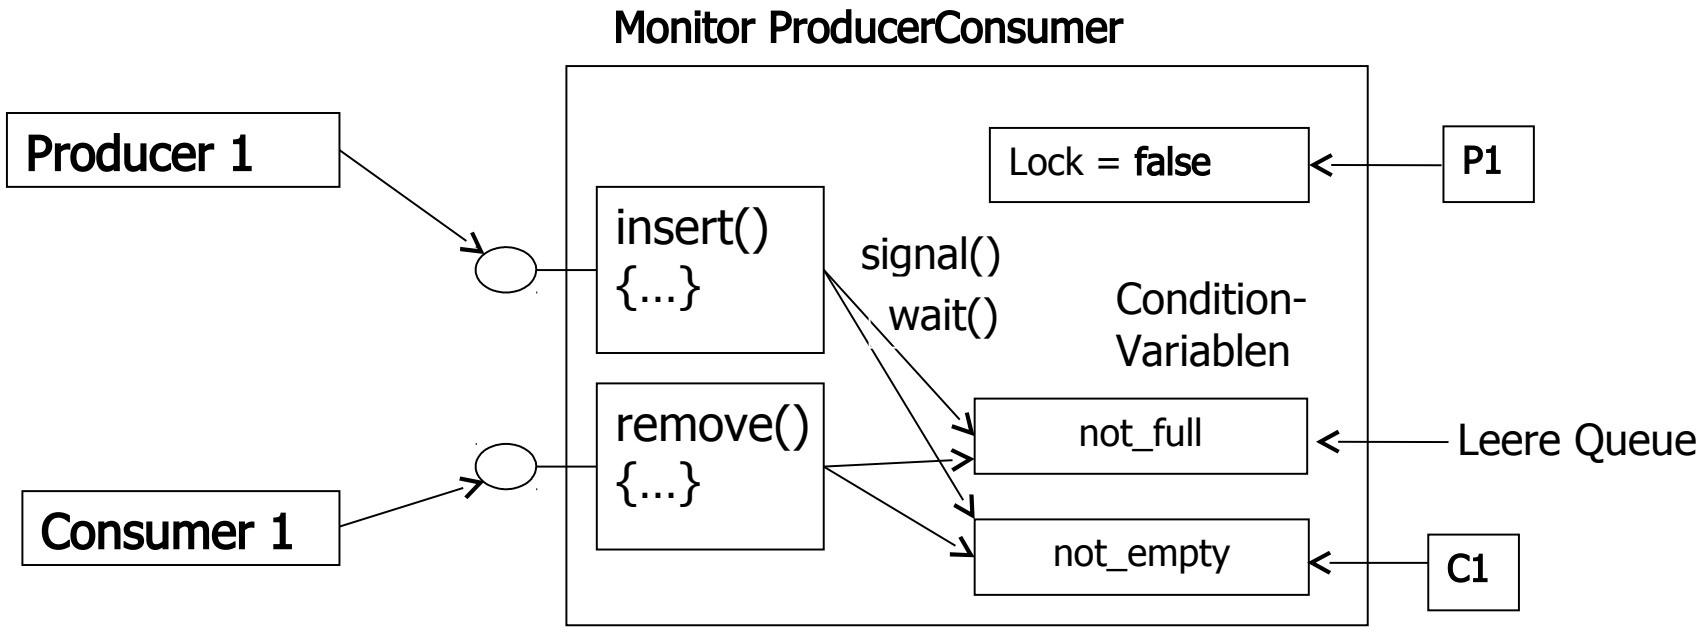

Monitore, Producer-Consumer, Szenario 1 (5)

- Producer 1 produziert
- Anm: signal() wirkt nur, wenn ein Thread darauf wartet, sonst hat es keine Wirkung und wird nicht gespeichert

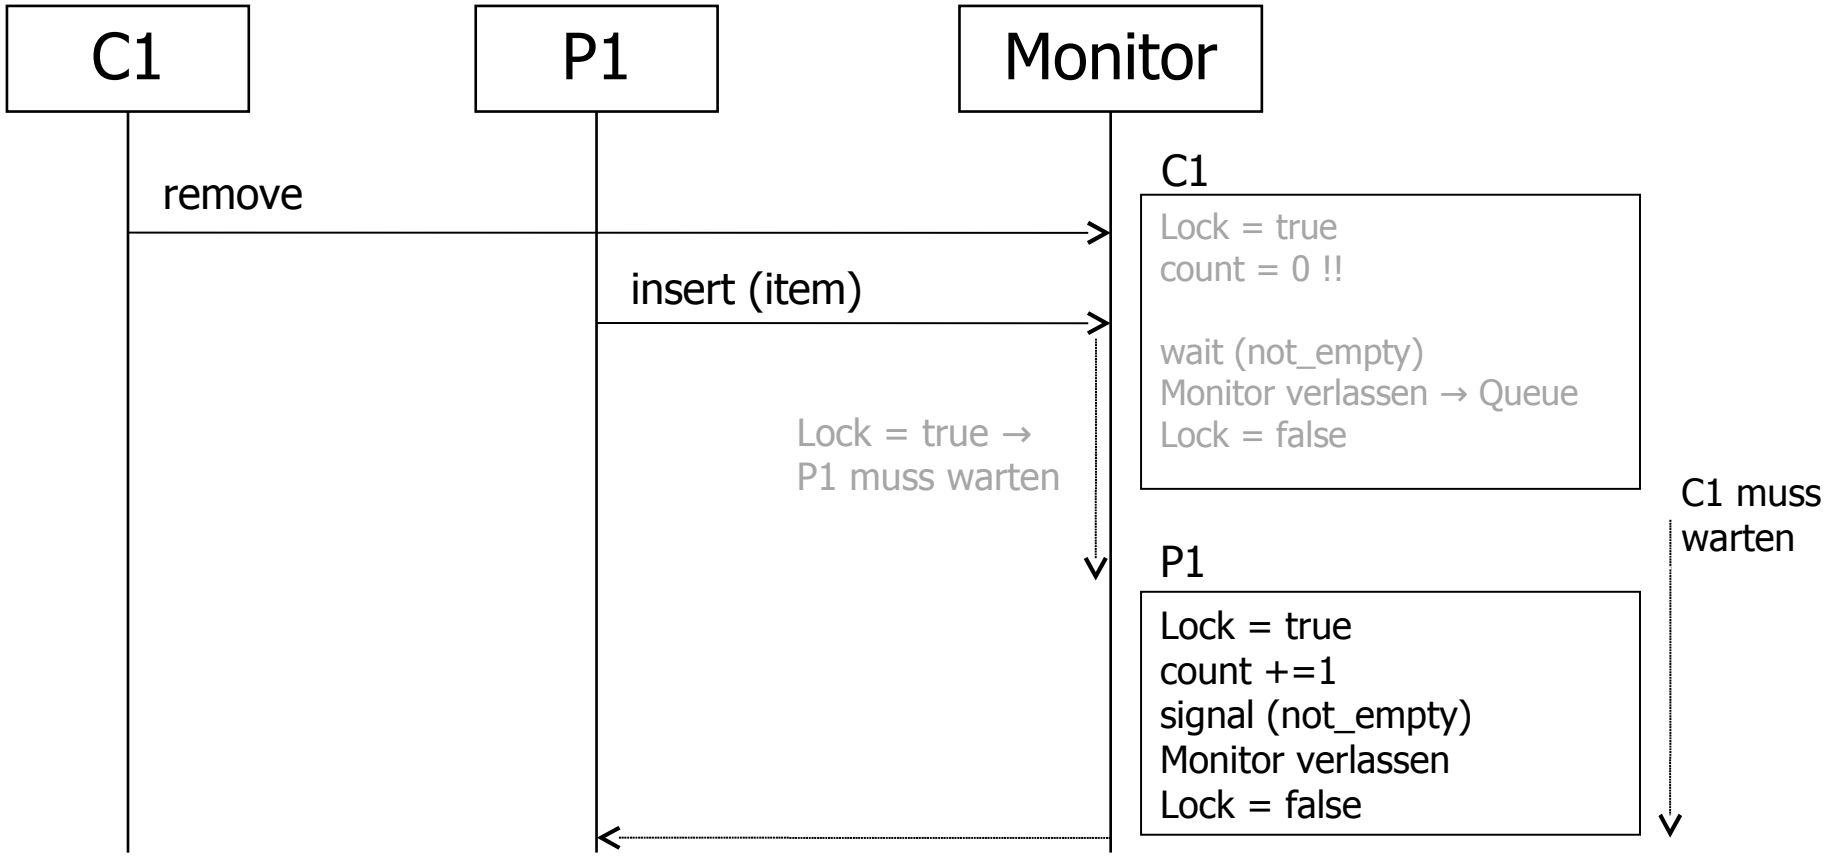

Monitore, Producer-Consumer, Szenario 1 (6)

- Consumer 1 kann nun konsumieren

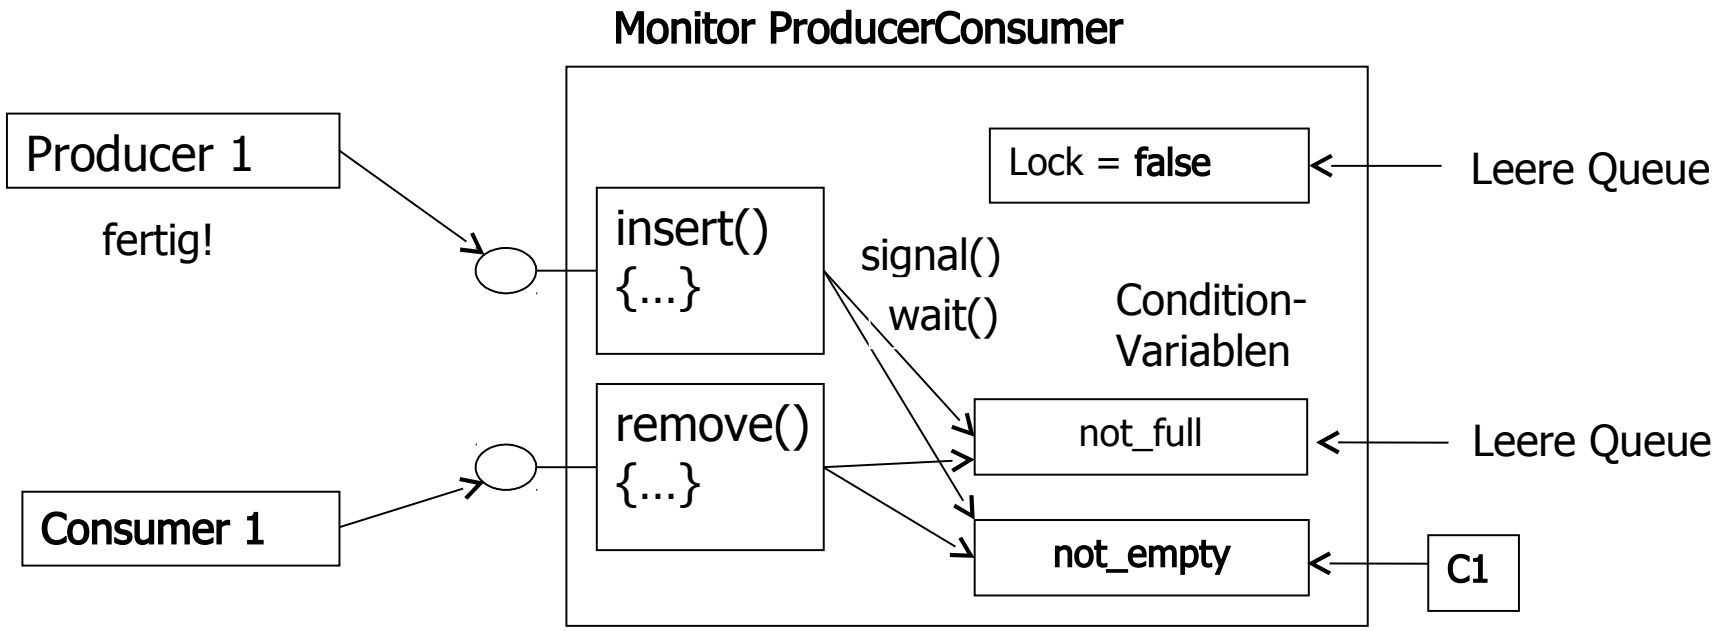

Monitore, Producer-Consumer, Szenario 1 (7)

- Consumer 1 konsumiert

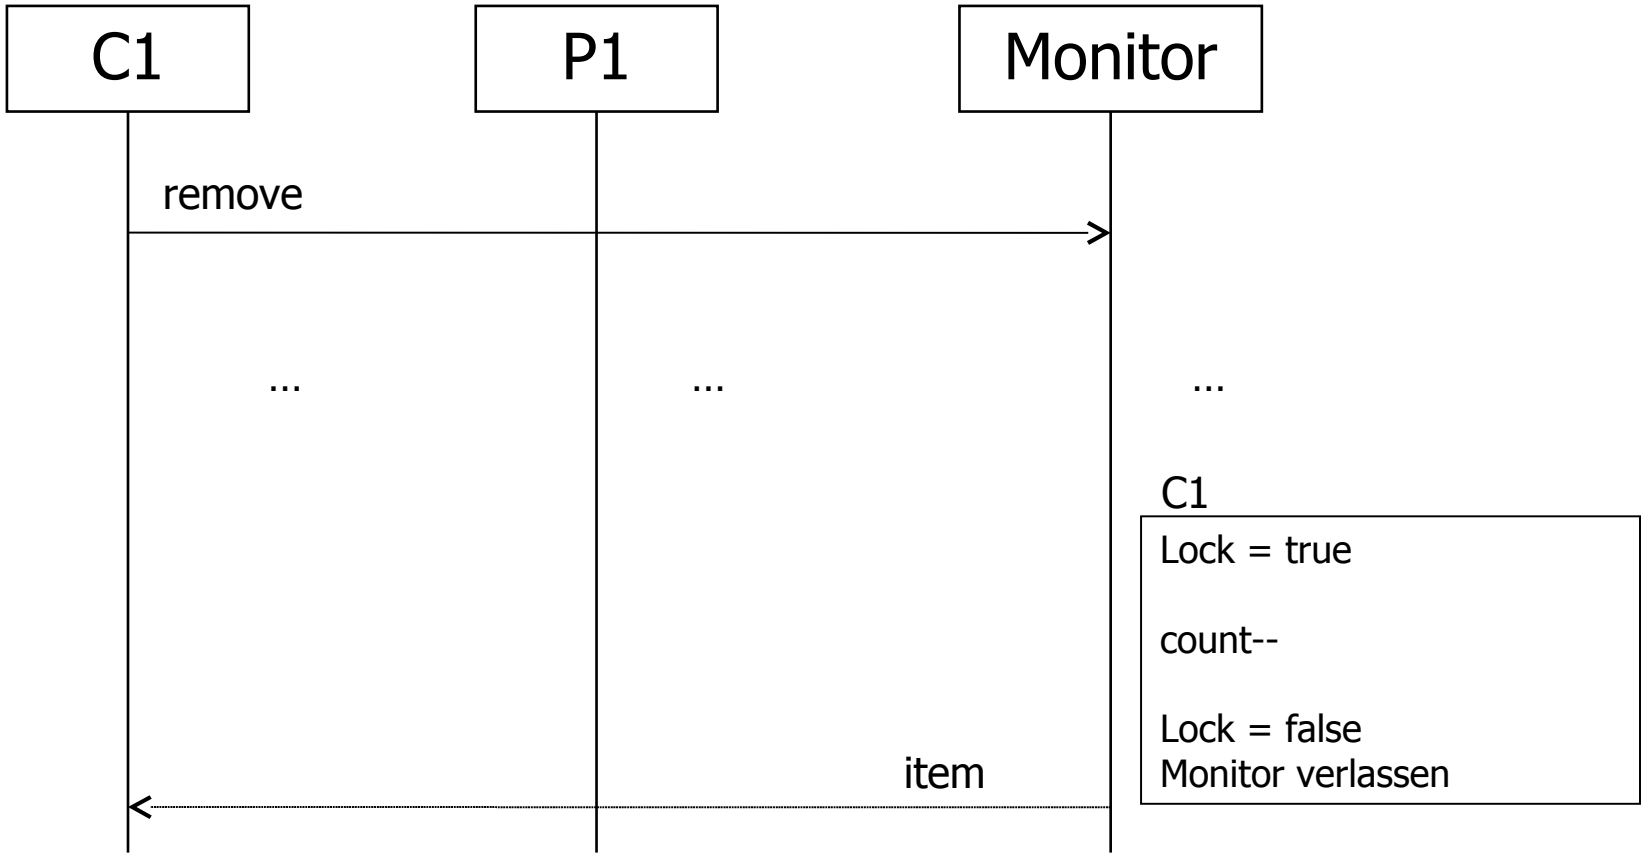

Monitore, Producer-Consumer, Szenario 2 (1)

- Anderes Szenario: Producer 1 möchte als erster produzieren

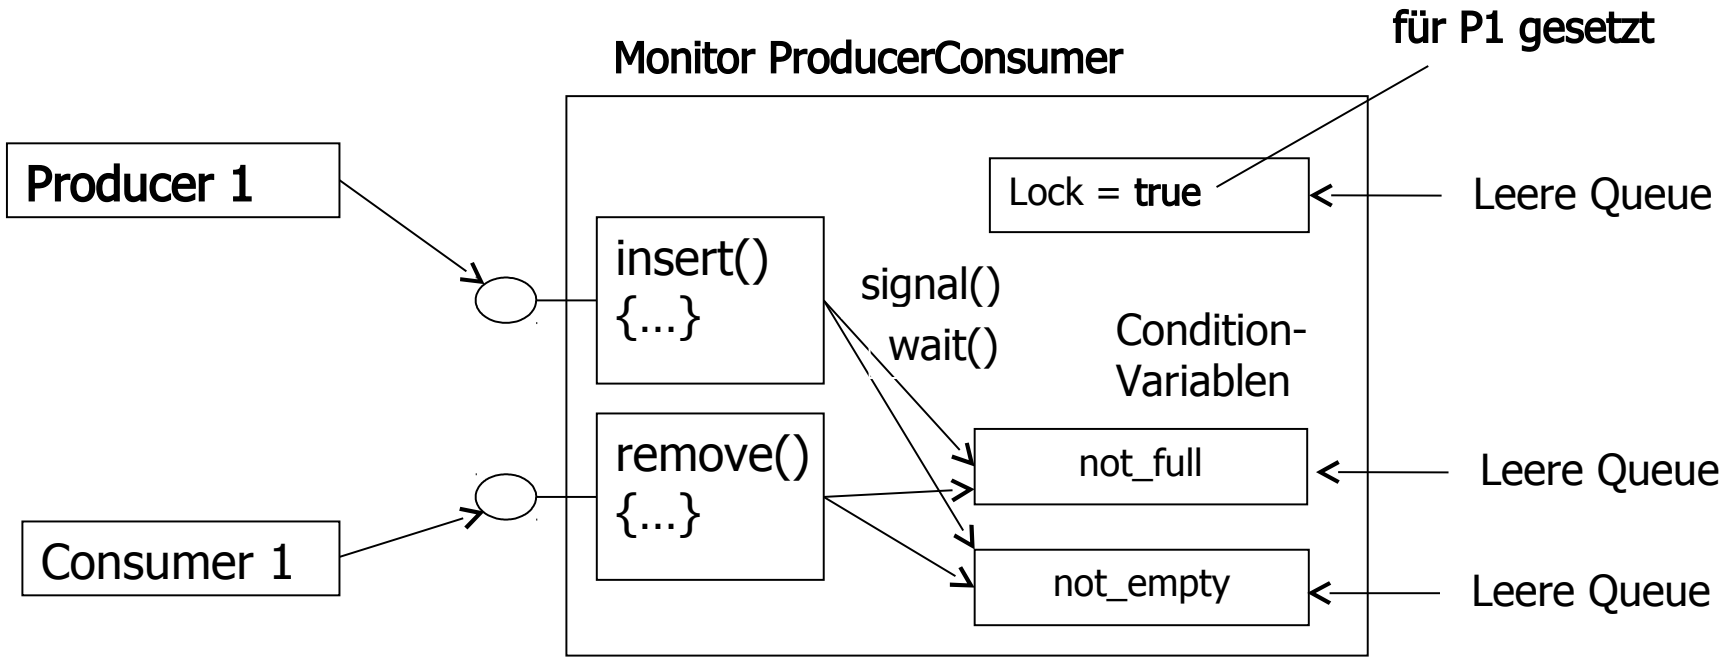

Monitore, Producer-Consumer, Szenario 2 (2)

- Consumer 1 muss warten bis Producer 1 den Monitor verlassen hat und konsumiert dann

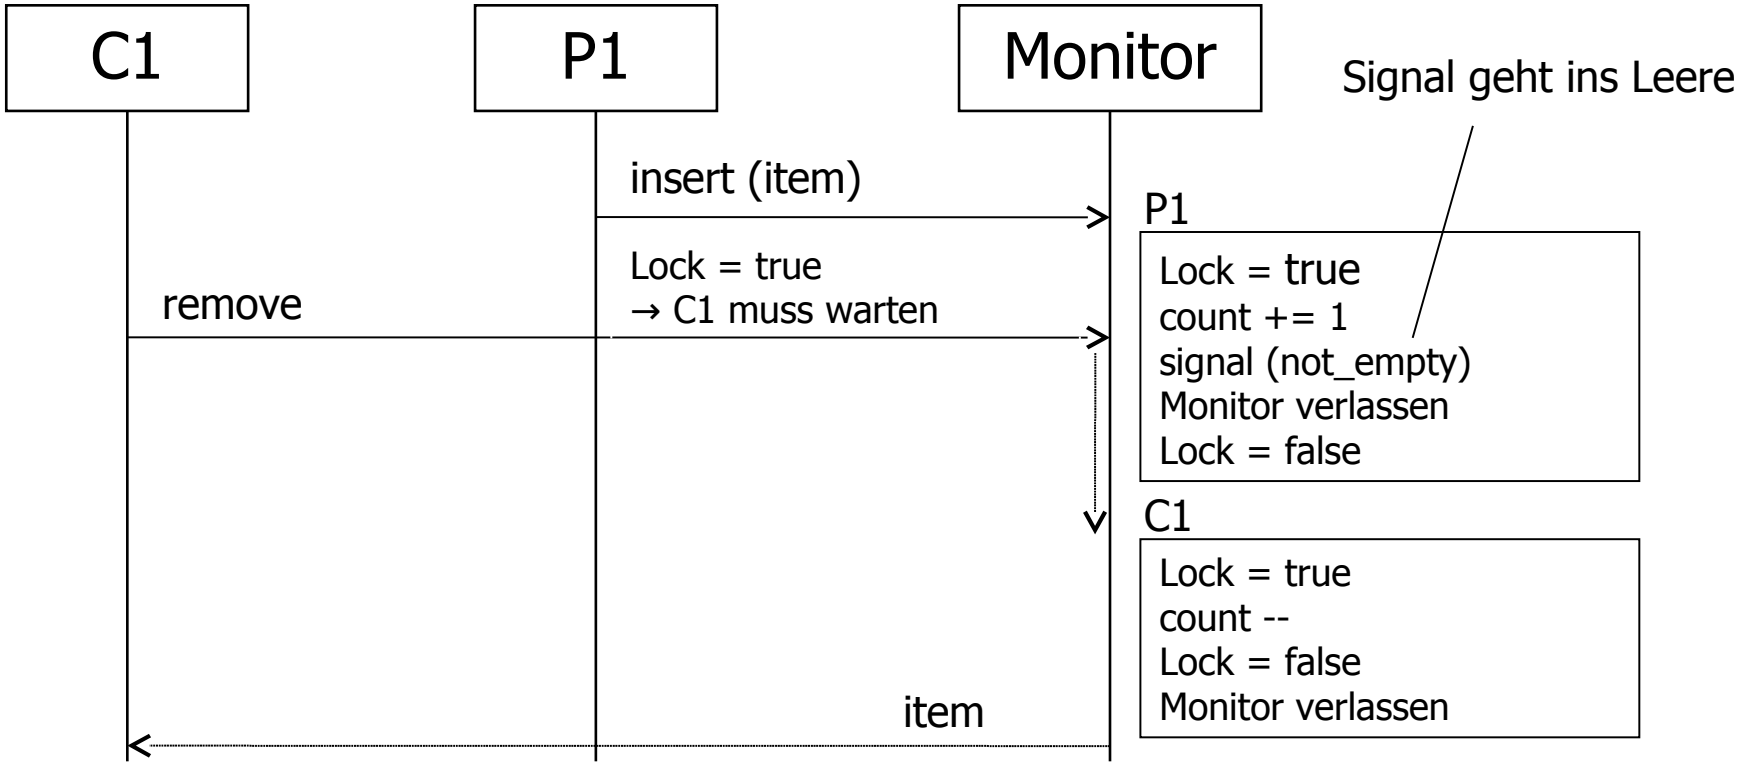

Überblick

1. Monitore
2. **Java-Synchronisation**
3. Deadlocks

Java: die Synchronisationsprimitive „synchronized“

- Der Modifier *synchronized* dient der Festlegung kritischer Abschnitte:
  - einzelne Codeblöcke
  - Methoden eines Objekts
- Anmerkung:
  - **Thread-safe** (Syn.: eintrittsinvariant, reentrant, wiedereintrittsfähig) heißt eine Klasse oder Methode, wenn sie bedenkenlos in einer nebenläufigen Thread-Umgebung genutzt werden kann
  - Problematisch: Klassenvariablen, globale Variablen

Java-Monitore: die Synchronisationsprimitive „synchronized“

- Zugriffsserialisierte Methode

```
public synchronized void method1()
{
    // geschützter Codebereich
}
```

- Zugriffsserialisierter Anweisungsblock

```
...
XyObject object1 = new XyObject(...);

synchronized (object1)
{
    // geschützter Codebereich
}
```

Monitore: Java-Monitor

signal-and-continue

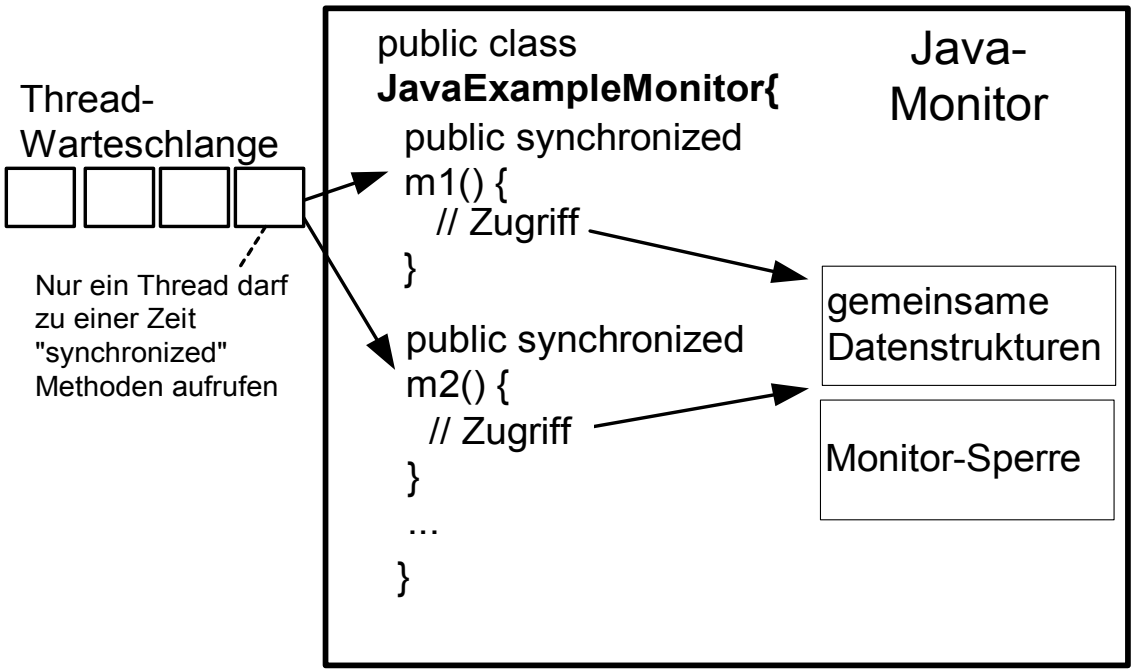

Java-Monitore: die Synchronisationsprimitive „synchronized“

- Anwendung auf ganze Methoden
  - Das betroffene Objekt wird vor Zugriffen anderer Instanzen gesperrt
  - Sperre wird gehalten, bis die Methode abgearbeitet ist
  - Wird darüber hinaus der Modifier *static* bei der Methodendefinition benutzt, so wird die ganze Klasse gesperrt, bis die Methode abgearbeitet ist

Java-Monitore: „Implizite Monitore“

- *synchronized* wird in der JVM über eine Monitor-Variante mit **einer** Sperre und **einer** Condition-Variable implementiert.
- Für jedes Objekt, das mind. eine *synchronized*-Methode hat, wird von der JVM ein eigener Monitor ergänzt
- Der Monitor realisiert das Sperren und Warten, wenn ein Thread auf eine *synchronized*-Methode zugreift
- Sperre wird aufgehoben, wenn Thread die Methode verlässt

Java-Monitore: Kritikpunkte

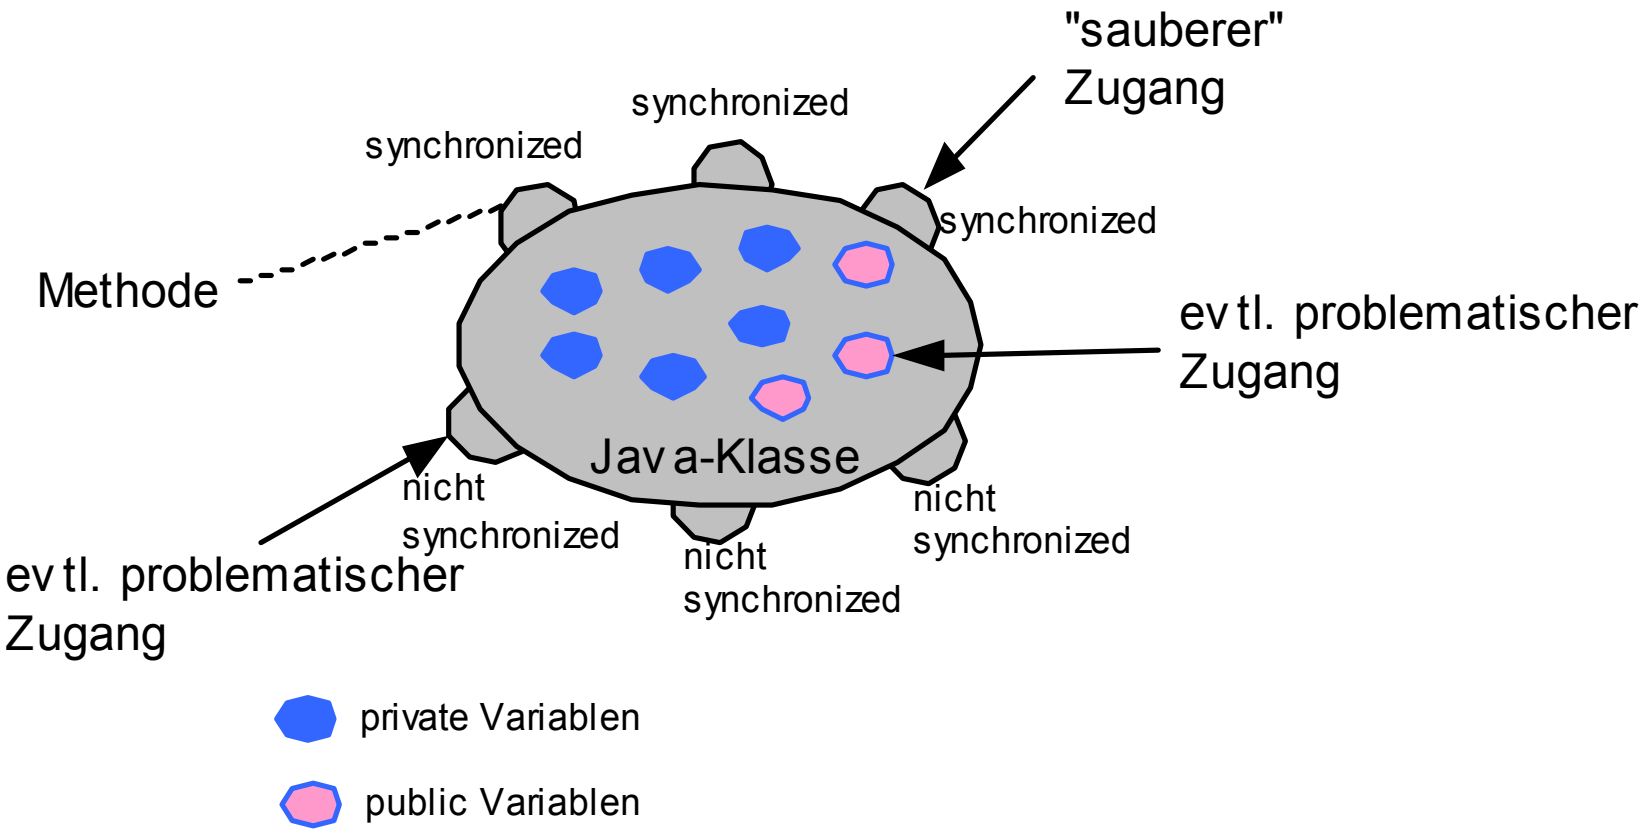

Threads in Java (Wiederholung)

- Nebenläufigkeit wird durch die Klasse *Thread* aus dem Package java.lang unterstützt
- Realisiertes Basiskonzept in der JVM: Monitore
- Eigene Klasse definieren, die von Thread abgeleitet ist und die Methode run() überschreiben
- Alternative: In einer Klasse das Interface *Runnable* implementieren und die Methode run() schreiben
  - Hat Vorteile wegen fehlender Mehrfachvererbung in Java
  - Wird daher meistens verwendet

Beispiel:
Zähler durch mehrere Threads hochzählen

- Eine einfache Objektklasse verwaltet einen Zähler
- Mehrere Threads greifen über die Methoden get() und set() auf den Zähler zu
- Zunächst wird das Problem ohne Synchronisierung gelöst
  - Was passiert?
- Dann wird der kritische Abschnitt synchronisiert
  - Was passiert nun?
- Bringen Sie die Anwendung unter Windows zum Laufen und testen sie diese mit verschiedenen Parametern

Beispiel:
Zähler durch mehrere Threads hochzählen

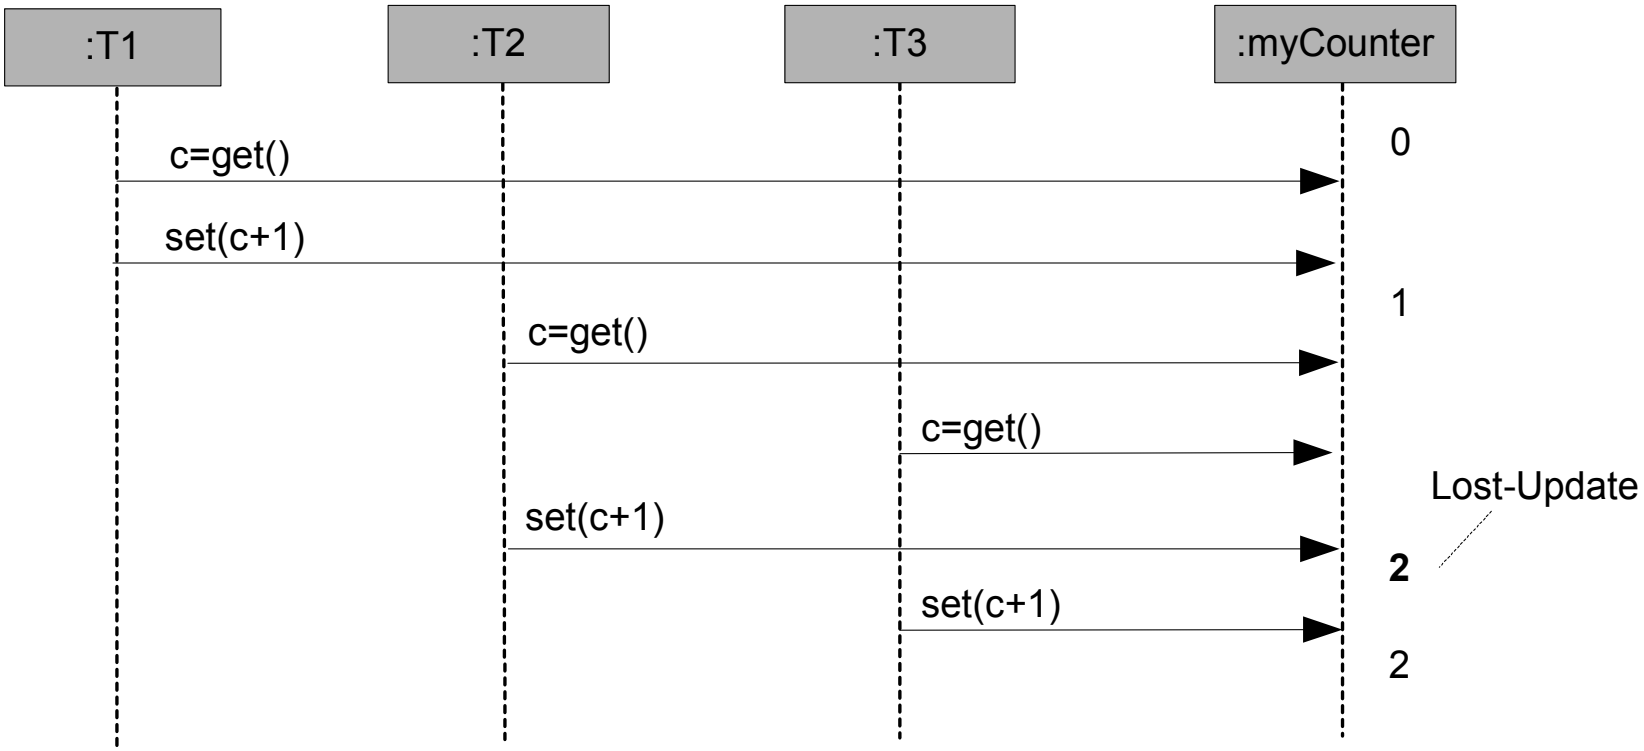

Beispiel: Zähler durch mehrere Threads hoch zählen

- Code für Counter

```
package Threads;
import java.io.*;

class CounterObject {
	private int count = 0;

	CounterObject() {
		// Nichts zu konstruieren
	}

	void set(int newCount) {
		count = newCount;
	}

	int get() {
		return count;
	}
}
```

Beispiel: Zähler durch mehrere Threads hoch-zählen

- Code für Thread-Klasse (nicht synchronisiert)

```
class CountThread1 extends Thread {
    private CounterObject myCounter;
    private int myMaxCount;
    CountThread1(CounterObject c, int maxCount)
    {
        myCounter = c;
        myMaxCount = maxCount;
    }
    public void run() {
        System.out.println("Thread " + getName() + " gestartet");
        for (int i=0;i<myMaxCount;i++){

            // Kritischer Bereich
                int c = myCounter.get();
                c++;
                myCounter.set(c);
            // Ende des kritischen Bereichs
        }
    }
}
```

Beispiel: Zähler durch mehrere Threads hoch-zählen

- Code für Thread-Klasse (synchronisiert)

```
class CountThread2 extends Thread {
    private CounterObject myCounter;
    private int myMaxCount;

    CountThread2(CounterObject c, int maxCount) {
        myCounter = c;
        myMaxCount = maxCount;
    }
    public void run() {
        System.out.println("Thread " + getName() + " gestartet");
        for (int i=0;i<myMaxCount;i++){
            synchronized (myCounter) {
                int c = myCounter.get();
                c++;
                myCounter.set(c);
            }
        }
    }
}
```

Methoden zur expliziten Synchronisierung (1)

- *wait()*
  - Thread geht in Wartezustand bis ein notify()- oder notifyAll()-Aufruf eines anderen Threads abgesetzt wird, der zum gleichen kritischen Abschnitt passt
- *wait(long timeout)*
  - Thread geht max „timeout" ms in einen Wartezustand (sonst wie wait())
- *notify()*
  - Weckt (mind.) einen wartenden Thread auf
- *notifyAll()*
  - Weckt alle wartenden Thread auf

Methoden zur expliziten Synchronisierung (2)

- wait() und notify() dürfen **nur innerhalb eines mit synchronized geschützten Abschnitts** aufgerufen werden
- wait() blockiert den Thread selbst, **die Sperre für den kritischen Abschnitt wird freigegeben**
- wait()/notify() ist **laufzeitkritisch**, Signalisierung darf nicht zu früh kommen, sonst geht sie ins Leere
  - Lösung: wait() in while-Schleife aufrufen
- notify() **garantiert nicht**, dass genau ein Thread aufgeweckt wird
- **Kein Warteschlangenmechanismus** implementiert, also nicht absolut fair

Java-Thread-Zustände gemäß API (1) (siehe Enum Thread.State)

- New
  - Noch nicht gestarteter Thread
- Runnable
  - Thread läuft in JVM, wartet aber evtl. auf Ressourcen des Betriebssystems (Prozessorzuteilung); Thread in diesem Zustand muss also nicht unbedingt eine CPU nutzen (Zuteilung erfolgt über Betriebssystem)
- Blocked
  - Thread ist blockiert und wartet auf einen Monitor-Lock, um in einen Synchronized-Block zu gelangen oder kann nach einem wait()-Aufruf wieder in einen kritischen Abschnitt eintreten

Java-Thread-Zustände gemäß API (2) (siehe Enum Thread.State)

- Waiting
  - Thread wartet auf einen anderen Thread, um eine Aktion ausführen zu können. Thread hat wait() oder join() ohne Zeitangabe aufgerufen
- Timed Waiting
  - Thread wartet auf das Auslaufen einer vorgegebenen Zeitspanne. Thread hat wait() oder join() mit Zeitangabe oder sleep() aufgerufen
- Terminated
  - Thread hat seine Arbeit abgeschlossen

Verfeinerter Zustandsautomat für einen Java-Thread

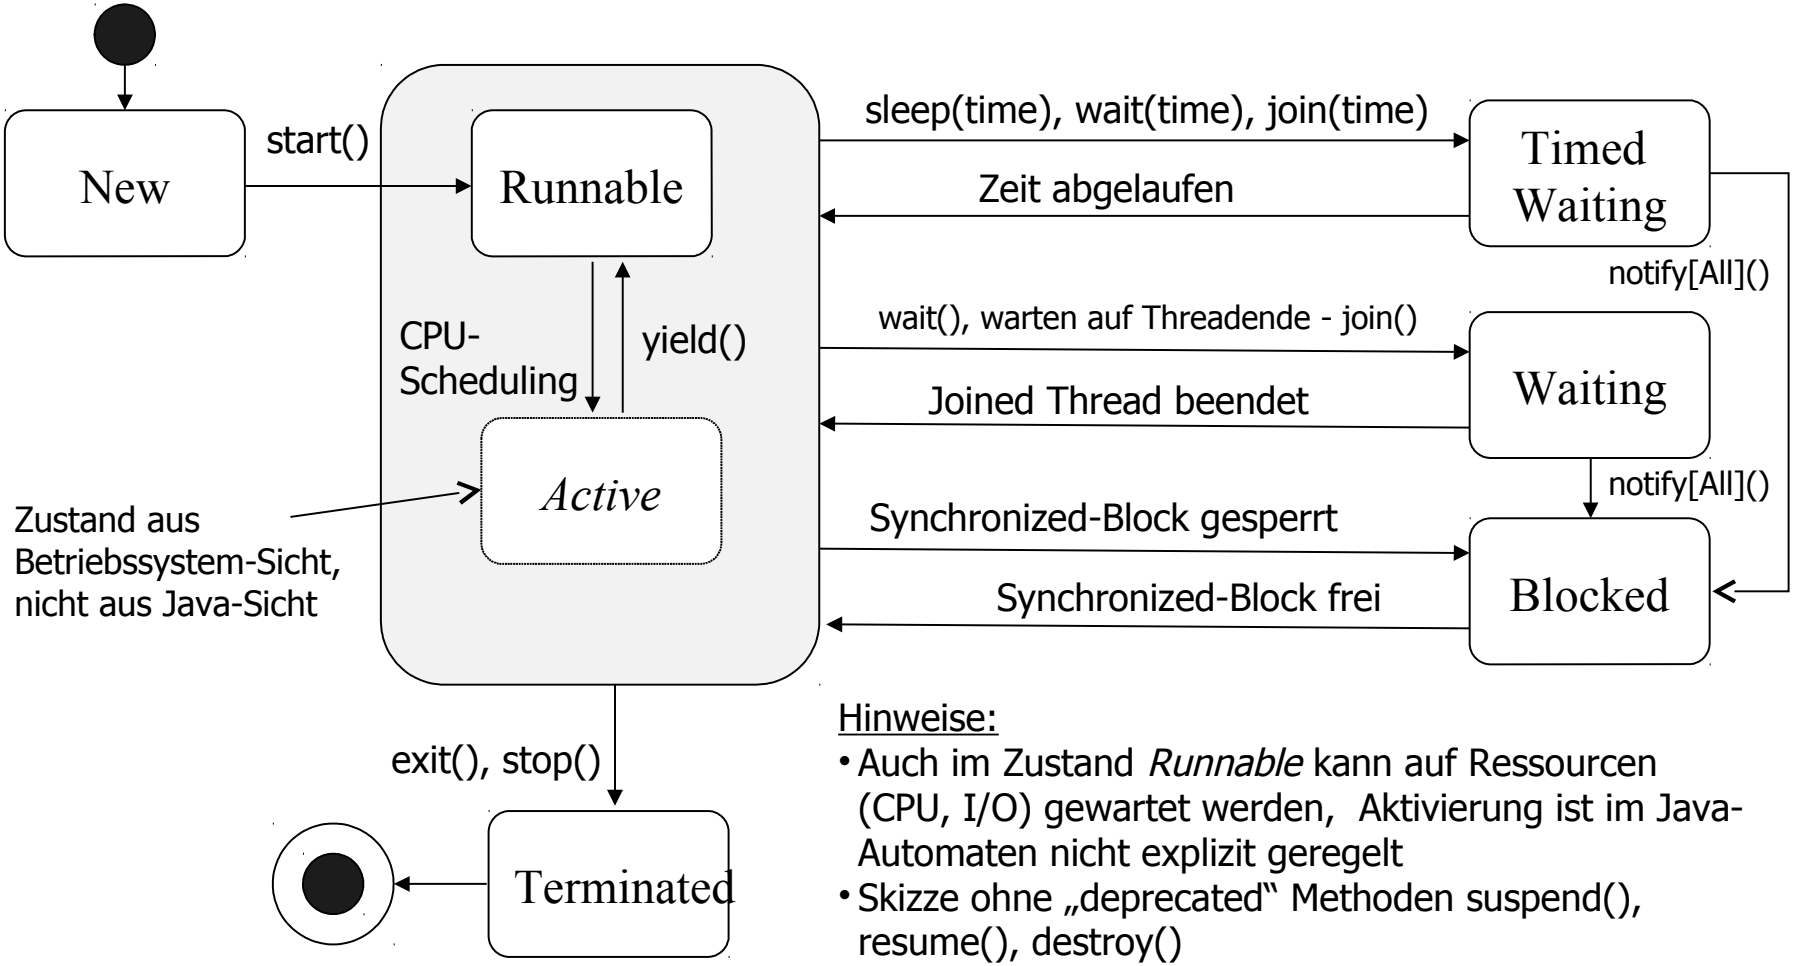

Hinweise:

- Auch im Zustand *Runnable* kann auf Ressourcen (CPU, I/O) gewartet werden, Aktivierung ist im Java-Automaten nicht explizit geregelt
- Skizze ohne „deprecated" Methoden suspend(), resume(), destroy()
- Thread.yield()-Aufruf bewirkt, dass CPU abgegeben wird

Beispiel zur expliziten Synchronisation
Eigene Semaphor-Implementierung

Zürcher Hochschule für Angewandte Wissenschaften
School of Engineering

```
class MySemaphor {
 private int max;          // Anzahl der maximal möglichen Threads im kritischen Abschnitt
 private int free;         // Anzahl der verfügbaren Plätze im kritischen Abschnitt (so viele
                           // Threads dürfen noch in den kritischen Abschnitt rein)
 private int waiting;      // Anzahl der in der P-Operation mit wait wartenden Threads (so
                           // viele Threads möchten aktuell in den kritischen Abschnitt rein)

public MySemaphor() {
   this(0);
 }
public MySemaphor(int i) {
   if (i >=0) {
            max = i;
   } else {
            max = 0;
   }
   free = max;
   waiting = 0;
 }

protected void finalize() throws Throwable {...}
```

Beispiel zur expliziten Synchronisation Semaphor-Implementierung

Zürcher Hochschule für Angewandte Wissenschaften
School of Engineering

```
/**
  * P-Operation
  */
public synchronized void P()
{
   while (free <= 0)
   {
        waiting++;          // Anzahl der wartenden Threads erhöhen
        try {
             this.wait();
        } catch (InterruptedException e) {}

         waiting--;         // Anzahl der wartenden Threads vermindern
   }
   free--;                  // Jetzt erst Semaphorzähler vermindern
 }
```

Beispiel zur expliziten Synchronisation
Semaphor-Implementierung

Zürcher Hochschule für Angewandte Wissenschaften
School of Engineering

```
/**
  * V-Operation
  */
 public synchronized void V()
{
   free++;  // Semaphorzähler erhöhen

   if (waiting > 0)
   {
      // Nur wenn ein anderer Thread wartet,
      // diesen mit notify benachrichtigen
      this.notify();
   }
 }
```

Java-Synchronisation: Abschließende Anmerkungen

- Die Synchronisation von Threads mit „synchronized" kann problematisch für die Performance sein
  - Monitor-Verwaltung kostet etwas
  - Man muss aufpassen, da zu große kritische Abschnitte zu Leistungseinbußen führen
- Programmierung von Threads ist gefährlich, da man Synchronisationsprobleme leicht übersehen kann
  - Ist ein Codestück, das zu serialisieren ist, nicht mit „*synchronized*" serialisiert, dann wird es irgendwann mal ein Problem geben, auch wenn man es nicht gleich bemerkt!

Überblick

1. Monitore
2. Java-Synchronisation
3. **Deadlocks**

Deadlocks: Definition

- Prozesse bzw. Threads können sich gegenseitig behindern oder sogar blockieren
  - Programme können nicht mehr ausgeführt werden
- Das typische Problem:
  - Prozess P1 hat das Betriebsmittel B1 reserviert und wartet auf B2, dass aber von P2 reserviert ist
  - P2 wiederum wartet auf B1
  - Beide Prozesse warten ewig
- Hier haben wir es mit einer **Verklemmung** bzw. mit einem **Deadlock** zu tun

Deadlocks: Modellierung

- Klassischer Deadlock mit zwei Prozessen und zwei Betriebsmitteln (Ressourcen)
- Zur Darstellung nutzt man u.a. Betriebsmittelbelegungsgraphen

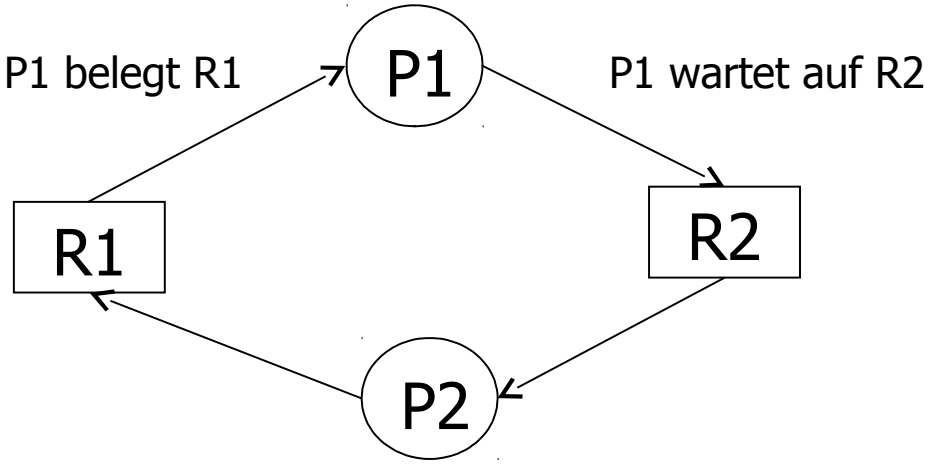

Deadlock als Petrinetz: vor der Deadlocksituation

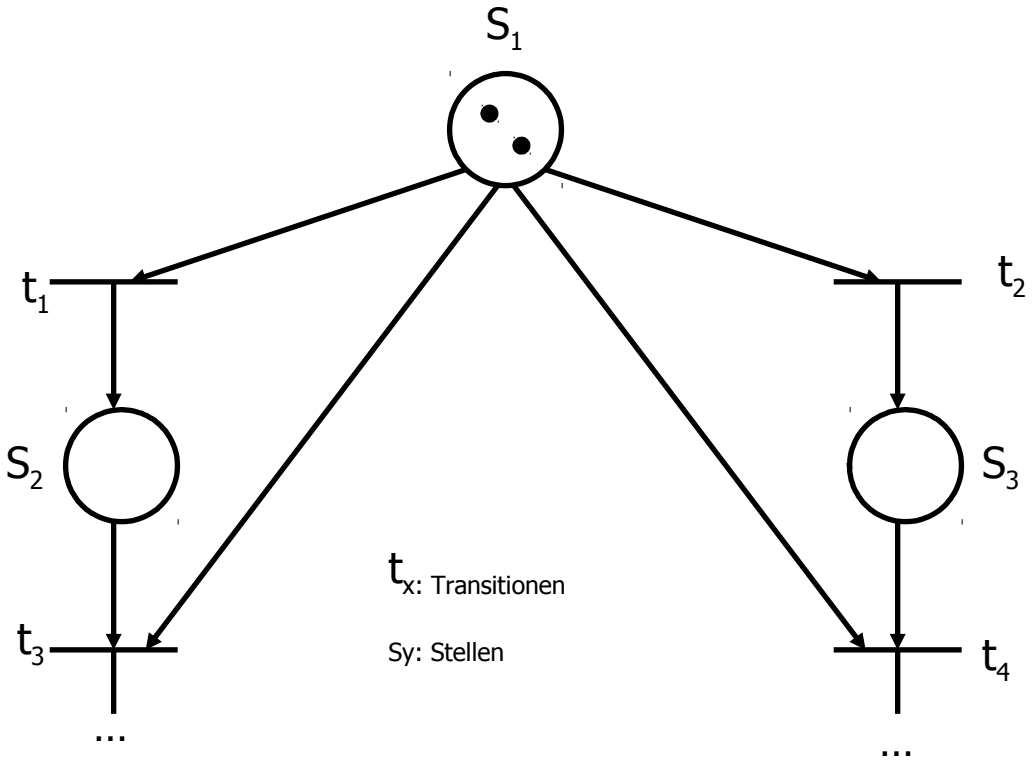

- Wenn t_1 und t_2 gleichzeitig schalten, liegt ein Deadlock vor, da S_1 nicht mehr feuern kann

Deadlock als Petrinetz: Deadlocksituation

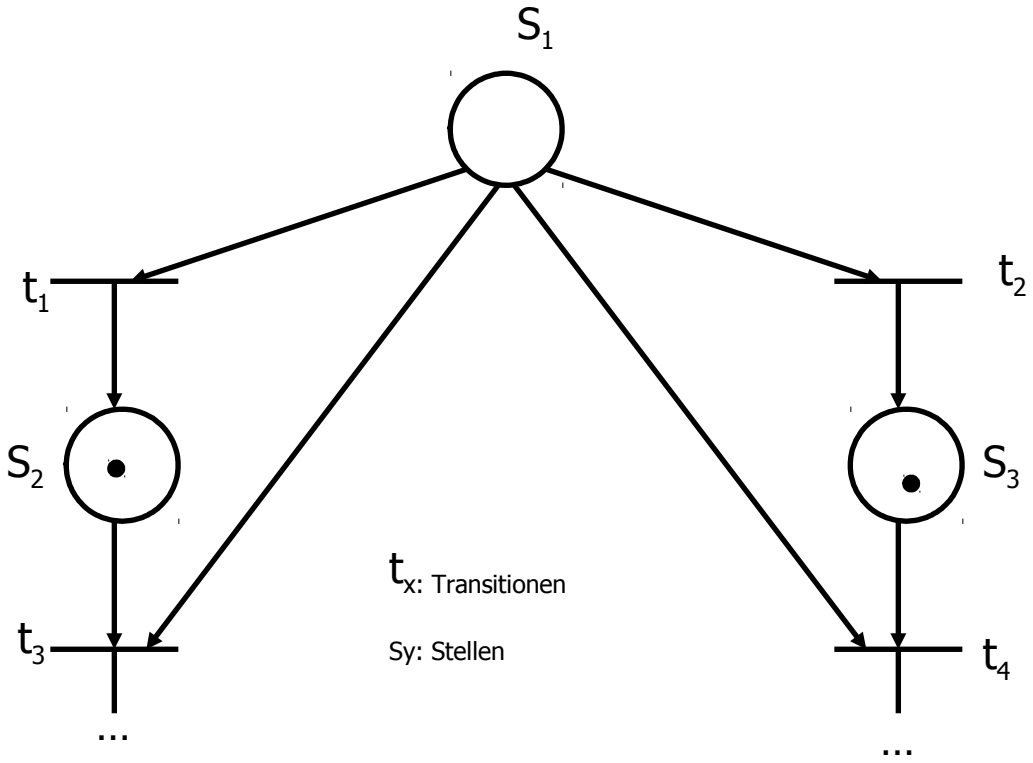

- Wenn t_1 und t_2 gleichzeitig schalten, liegt ein Deadlock vor, da S_1 nicht mehr feuern kann

Deadlock: Bedingungen

- Es gibt vier notwendige und hinreichende Bedingungen für einen Deadlock:
  - **(1) Mutual exclusion**
    - Jedes beteiligte Betriebsmittel ist entweder exklusiv belegt oder frei
  - **(2) Hold-and-wait**
    - Prozesse belegen bereits exklusiv Betriebsmittel (mind. eines) und fordern noch weitere an: Die Anforderung wird also nicht auf einmal getätigt
  - **(3) No preemption**
    - Es ist kein Entzug eines Betriebsmittels möglich, Prozesse müssen sie selbst wieder zurückgeben
  - **(4) Circular waiting** (hinreichend)
    - Zwei oder mehr Prozesse müssen in einer geschlossenen Kette auf Betriebsmittel warten, die der nächste reserviert hat

Java-Beispiel: Deadlocksituation

```
public class myDeadlock  {
    public static void main(String[] args) {
        final Object resource1 = new Object(); // Dummy-Objekte nur zur Demonstration
        final Object resource2 = new Object();

         Thread t1 = new Thread( new Runnable()  {
            public void run()  {
            synchronized (resource1)  {
            //  mach etwas
                synchronized (resource2)  {
                //  mach etwas
            } } } }
          );

         Thread t2 = new Thread( new Runnable()  {
            public void run()  {
            synchronized (resource2)  {
            //  mach etwas
                synchronized (resource1)  {
                //  mach etwas
            } } } }
        );

        t1.start(); t2.start();
    }
}
```

Zum ausprobieren!

Deadlock: Behandlung

- Es gibt vier verschiedene Strategien zur Deadlock-Behandlung:
  - **Ignorieren**
    - Vogel-Strauß-Strategie: „Kopf in den Sand"
  - **Erkennen und beheben**
    - Deadlocks sind grundsätzlich zugelassen, werden aber über Betriebsmittelbelegungsgraphen erkannt
    - Beheben durch:
      - Rollback
      - Prozessabbruch
      - Transaktionsabbruch
  - **Dynamisches Verhindern**
    - Ressourcen vorsichtig zuteilen
  - **Vermeiden**
    - Eine der vier Bedingungen muss unerfüllt bleiben

Überblick und Zusammenfassung

- ✓ Monitore
- ✓ Java-Synchronisation
- ✓ Deadlocks